



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Информационные системы и телекоммуникации»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ
НА ТЕМУ:

«Информационная система для классификации кожных заболеваний на изображении с использованием искусственных нейронных сетей»

Студент группы ИУЗ-81Б

(Подпись, дата)

В.В. Киселев

Руководитель ВКР

(Подпись, дата)

С.А. Сакулин

Нормоконтролер

(Подпись, дата)

А.Р. Кадырбаева

2023 г.

АННОТАЦИЯ

Расчетно-пояснительная записка 73 с., 60 рис., 4 табл., 15 источников.

КЛАССИФИКАЦИЯ ИЗОБРАЖЕНИЙ, СЕГМЕНТАЦИЯ ИЗОБРАЖЕНИЙ, ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ

Объектом разработки является информационная система для классификации кожных заболеваний на изображении с использованием искусственных нейронных сетей.

Цель работы — модернизация алгоритмов распознавания кожных заболеваний на изображении для определения абсолютной площади поражения.

Поставленная цель достигается за счет применения алгоритмов выделения пор на коже, их подсчета, сопоставления полученного значения с известной плотностью пор для данного участка кожи.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	7
1 Исследовательская часть	8
1.1 Описание классифицируемых изображений	8
1.2 Описание элементов на видимой части кожного покрова	9
1.3 Исследование аудитории приложения	10
1.4 Обоснование выбора библиотек для использования в программном продукте	21
1.5 Составление технического задания	21
2. Конструкторская часть	23
2.1 Обзор существующих приложений-аналогов	23
2.2 Обоснование актуальности новой разработки	25
2.3 Обзор методов для определения размера объекта на изображении	27
2.4 Выбор набора данных	30
2.5 Обзор архитектур нейронных сетей для классификации объектов на изображении	31
2.5.1 Архитектура ResNet	31
2.5.2 Архитектура EfficientNet	32
2.5.3 Архитектура DenseNet	33
2.5.4 Архитектура SwinV2	34
2.6 Подготовка данных для обучения	37
2.7 Обучение моделей	37
2.8 Сравнение результатов обучения различных архитектур	51
2.9 Модель для сегментации изображения	55
2.9.1 Выбор набора данных для обучение модели сегментации	55
2.9.2 Обоснование выбора архитектуры для модели сегментации кожного заболевания	56
2.9.3 Обучение модели сегментации	58
2.11 Алгоритм выделения пор на изображении	60
3. Технологическая часть	68
ЗАКЛЮЧЕНИЕ	71
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	73
ПРИЛОЖЕНИЕ А	
Графическая часть выпускной квалификационной работы	75
ПРИЛОЖЕНИЕ Б	76

ВВЕДЕНИЕ

В данной работе производится проектирование информационной системы для классификации кожных заболеваний на изображении. В настоящее время появляется все больше возможностей внедрять технологии машинного обучения в медицину, что связано с ростом доступности больших вычислительных мощностей. Информационная система предназначена для пользователей, которые хотят быстро получить информацию об области поражения кожным заболеванием.

Проектирование проводилось с учётом основных принципов:

- реализация методов, должна обеспечивать приемлемое время анализа изображения;

- информационная система должна обрабатывать изображения различных форматов;

Выполнение расчетов проводилось с использованием ЭВМ.

При выполнении технического проекта были проведены: анализ популярных современных архитектур нейронных сетей для классификации кожных заболеваний на изображении, реализован алгоритм сегментации и подсчета пор на поверхности кожи по изображению кожи.

1 Исследовательская часть

1.1 Описание классифицируемых изображений

Для определения площади поражения кожного заболевания по изображению, требуется знать размер какой-то части изображения. В данном случае на вход системы поступает изображение, которое представляет из себя фотографию области поражения кожного заболевания, которая сделана сверху вниз при хорошем освещении.

В центре фотографии находится область поражения. Вокруг неё находится кожный покров с порами, волосами. На изображении присутствует водяной знак, который сигнализирует о том, кому принадлежит изображение.

Область поражения выделяется визуально, она может быть различной формы, может состоять из нескольких пятен (очагов), сильно различаться по цвету.



Рисунок 1 – Пример изображения кожного заболевания [1]

1.2 Описание элементов на видимой части кожного покрова

Кожный покров состоит из трех основных слоев: эпидермиса, дермы и подкожной жировой ткани.

Эпидермис – наружный слой кожи, состоящий из нескольких слоев клеток. Верхний слой, называемый роговым слоем, состоит из мертвых клеток, которые постепенно отслаиваются. Нижние слои эпидермиса содержат живые клетки, которые постоянно делятся и обновляются.




Рисунок 2 – Строение кожного покрова человека [2]

1.3 Исследование аудитории приложения

Вопрос доверия к технологиям искусственного интеллекта (ИИ) в медицине является очень важным и актуальным. С одной стороны, ИИ может принести значительные выгоды в медицине, такие как быстрое и точное диагностирование заболеваний, оптимизация лечения и улучшение результатов для пациентов. Однако, с другой стороны, существует ряд проблем и рисков, связанных с применением ИИ в медицине, которые могут подорвать доверие пациентов и врачей к этим технологиям.

Одна из основных проблем, связанных с применением ИИ в медицине, - это недостаток прозрачности и понимания того, как ИИ принимает свои решения. Это может вызвать беспокойство у пациентов и врачей, которые могут бояться ошибок или недостаточной точности диагностики и лечения. Некоторые также могут опасаться, что использование ИИ приведет к уменьшению роли человеческого врача в лечении и диагностике болезней.

Учитывая вышеперечисленные причины, по которым может быть низкое доверие к приложениям, распознающим заболевания при помощи ИИ, был проведен исследование в виде опроса с целью проверки гипотезы о том, что в настоящее время значительная часть людей доверяет ИИ в данном контексте.

Опрос проводился в феврале 2023 года. Большая часть респондентов - студенты московских вузов. Опрос проводился в системе Google Forms. За время исследования удалось получить 83 ответа от респондентов.

Первый вопрос задавался с целью узнать возраст респондентов и выглядел так: “Сколько Вам лет?” Респонденту было предложено ввести целое число. Результаты опроса приведены на рисунке 3 ниже.




Рисунок 3– Распределение ответов на вопрос о возрасте

Отношение к ИИ в некоторой области может отличаться в зависимости от того, является ли человек специалистом в ней. Второй вопрос задан с целью узнать, является ли респондент медиком. Он выглядел так: “У вас есть медицинское образование?”




Рисунок 4 – Распределение ответов на вопрос о медицинском образовании

Анализируя распределение ответов по рисунку 4 можно сделать вывод, что большая часть респондентов является студентами медицинских специальностей. Далее будем учитывать, что ответы могут различаться у всей выборки и у немедиков.

Следующий вопрос помогает узнать, куда люди обращаются в первую очередь при небольшом ухудшении здоровья. Это важно знать, потому что разрабатываемый сервис как раз может быть полезен для получения быстрой диагностики. Вопрос выглядел так: “Вам кажется, что у Вас маленькие проблемы со здоровьем, куда Вы обратитесь в первую очередь?”. Было несколько вариантов ответа:

- 1) Никуда не буду обращаться;
- 2) Буду искать информацию в интернете;
- 3) Обращусь к специалисту.

У респондентов присутствовала возможность написать собственный вариант ответа.




Рисунок 5– Распределение ответов всей выборки на вопрос о том, куда в первую очередь обращаются респонденты при небольшом ухудшении здоровья




Рисунок 6– Распределение ответов среди немедиков на вопрос о том, куда в первую очередь обращаются респонденты при небольшом ухудшении здоровья

Сравнение ответов двух выборок можно сделать вывод, что не медики чаще ищут информацию в интернете и никуда не обращаются, реже обращаются к специалисту.

Следующий вопрос призван узнать, где люди ищут информацию о лечении кожного заболевания при появлении популярного симптома. Он выглядел так: “Представим, что у Вас появилось незнакомое покраснение, как вы попыботе вылечить это сначала?”.

Респондентам было предложено несколько вариантов ответов:

- 1) Не буду лечить;
- 2) Буду лечиться знакомыми методами и средствами;
- 3) Буду лечиться, используя найденные в интернете способы;
- 4) Запишусь на прием к специалисту.

У респондента была возможность написать собственный вариант ответа. Распределение полученных результатов можно увидеть на рисунках 7 и 8.




Рисунок 7– Распределение ответов всей выборки на вопрос о том, где люди ищут информацию о лечении кожного заболевания при появлении популярного симптома




Рисунок 8– Распределение ответов среди немедиков на вопрос о том, где люди ищут информацию о лечении кожного заболевания при появлении популярного симптома

Результаты практически одинаковые. Немедики реже лечатся знакомыми методами и средствами, чаще не лечат.

Следующий вопрос добавлен с целью того, чтобы понять, насколько респонденты доверяют информации в интернете, касающуюся здоровья: “Доверяете ли вы информации о здоровье в интернете?”.

Были предложены следующие варианты ответов:

- 1) Полностью доверяю;

- 2) Скорее доверяю;
- 3) Скорее не доверяю;
- 4) Полностью не доверяю.

У респондента была возможность написать собственный вариант ответа. Распределение полученных результатов можно увидеть на рисунках 9 и 10.




Рисунок 9— Распределение ответов всей выборки на вопрос о том, доверяет ли человек информации о здоровье в интернете




Рисунок 10– Распределение ответов среди немедиков на вопрос о том, доверяет ли человек информации о здоровье в интернете

Немедики чуть-чуть реже доверяют информации в интернете, чем вся выборка.

Следующий вопрос призван выяснить, доверяют ли респонденты технологиям искусственного интеллекта. Он выглядел следующим образом: “Сейчас набирают популярность технологии искусственного интеллекта. Будете ли Вы доверять результатам работы сервиса о здоровье, основанного на технологиях искусственного интеллекта?”.

Были предложены следующие варианты ответов:

- 1) Буду доверять;
- 2) Скорее буду доверять;
- 3) Скорее не буду доверять;

4) Не буду доверять.

У респондента была возможность написать собственный вариант ответа. Распределение полученных результатов можно увидеть на рисунках 11 и 12.

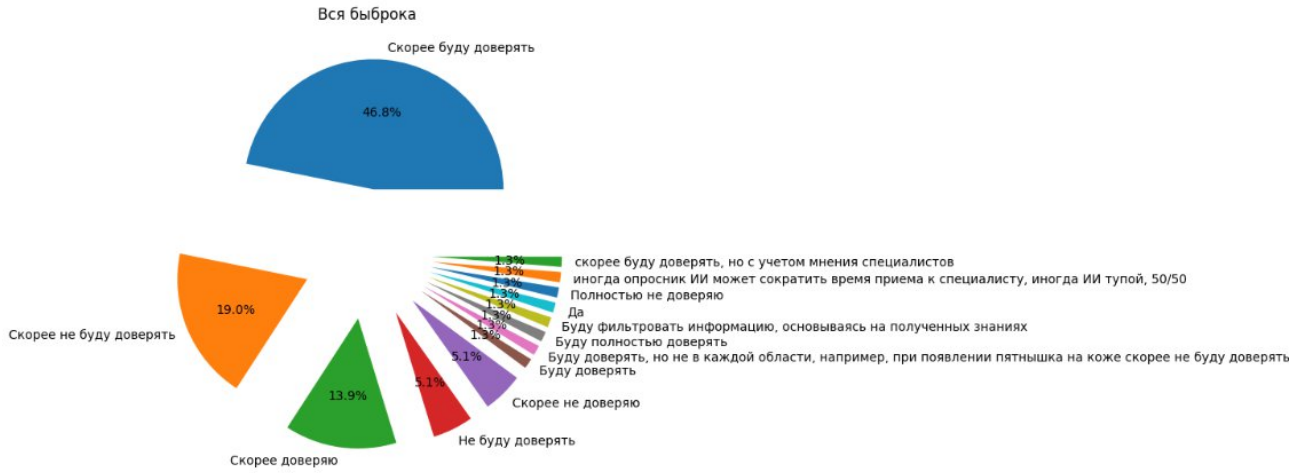


Рисунок 11– Распределение ответов всей выборки на вопрос о том, доверяет ли человек сервисам о здоровье, которые используют технологии искусственного интеллекта

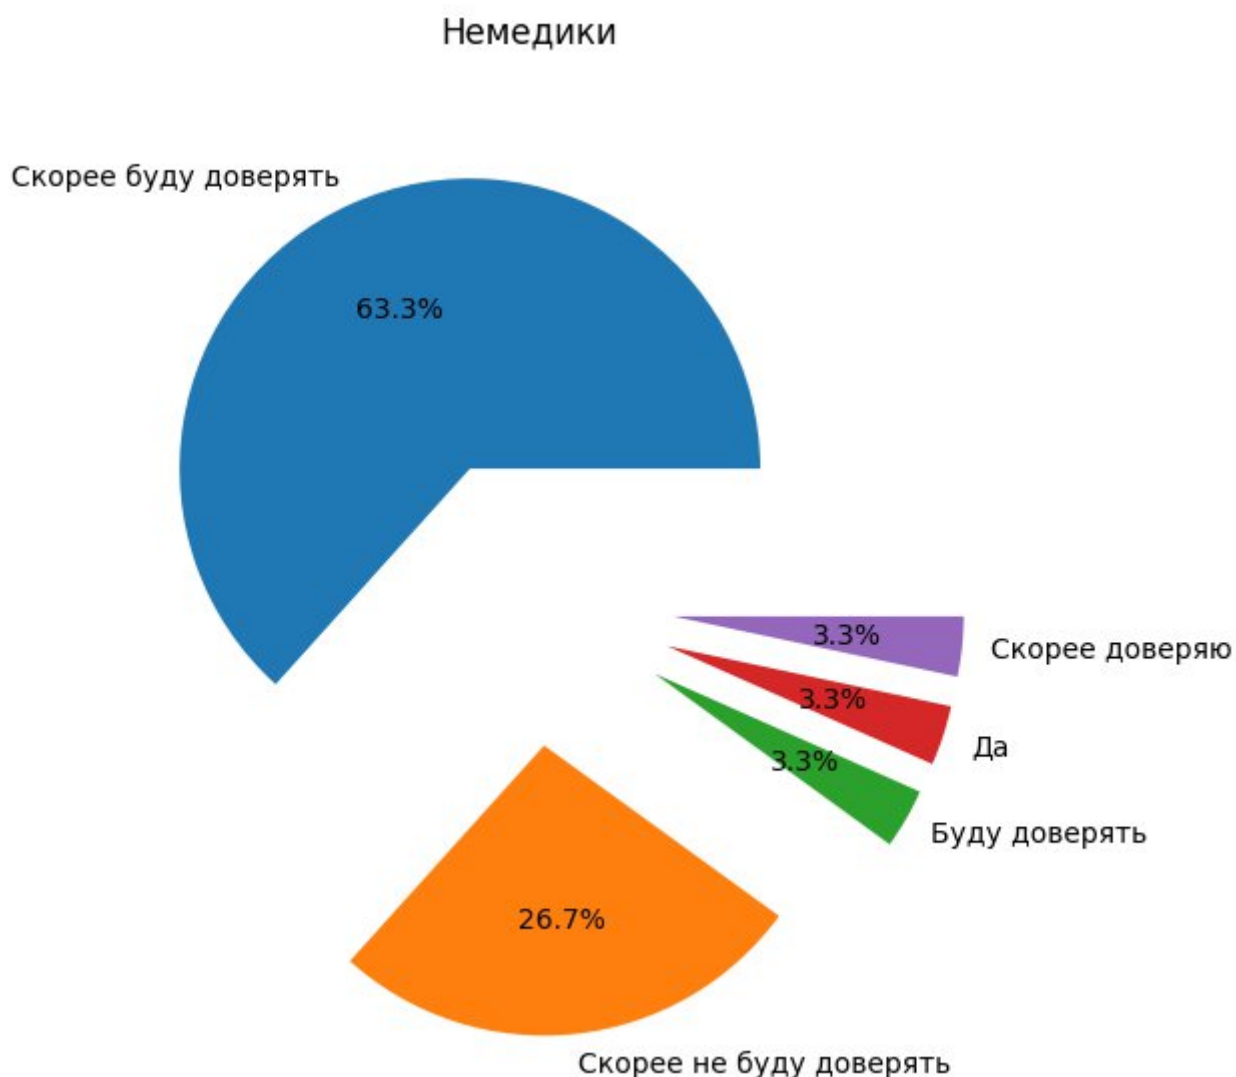


Рисунок 12– Распределение ответов среди медиков на вопрос о том, доверяет ли человек сервисам о здоровье, которые используют технологии искусственного интеллекта

Исходя из полученных результатов можно сделать вывод, что немедики больше доверяют ИИ, чем вся выборка

Следующий вопрос помогает понять, кому люди больше доверяют в вопросах диагностирования заболеваний. Он выглядел так: “Кому вы больше доверяете в вопросах диагностирования заболеваний?”.

Были предложены такие варианты ответов:

- 1) Ответам в интернете;
- 2) Технологиям обученного искусственного интеллекта.

У респондентов была возможность написать собственный вариант ответа. Распределение полученных результатов можно увидеть на рисунках 13 и 14.

интернете и ИИ. Разрабатываемый сервис не поможет тем, кто предпочитает обращение к специалисту. Однако он поможет тем, кто пытается диагностировать свое заболевание по информации в интернете, потому что использование сервиса занимает меньше времени.

По этой причине было решено убрать возможность написать собственный вариант ответа. На момент изменения в опросе приняло участие 68 человек. После изменений в исследовании участвовало 15 респондентов. Результат приведен на рисунке 15.




Рисунок 15 – Распределение ответов респондентов после изъятия возможности написать собственный вариант ответа на вопрос о том, чему больше доверяет человек в вопросах диагностирования заболеваний

Как видно на рисунке 15, большая часть людей больше доверяет ИИ. наше приложение будет полезно тем, кто при ответе на вопрос “Вам кажется, что у Вас маленькие \проблемы со здоровьем, куда Вы обратитесь в первую очередь?” выбрал вариант ответа “Буду искать информацию в интернете“, при ответе на вопрос “Кому вы больше доверяете в вопросах диагностирования заболеваний?” выбрал вариант ответа “Технологиям обученного искусственного интеллекта”. В результате подсчета получилось, что количество таких людей составляет 17.7 % от всей выборки.

1.4 Обоснование выбора библиотек для использования в программном продукте

В данный момент существуют два популярных фреймворка для машинного обучения: PyTorch, TensorFlow. Нельзя сказать, что один из них во всем лучше другого, каждый имеет свои сильные и слабые стороны, выбор зависит от решаемой задачи.

PyTorch обладает следующими преимуществами в сравнении с TensorFlow:

1. Простота использования: PyTorch имеет более простой и интуитивный интерфейс, что делает его более доступным для новичков в машинном обучении;
2. Динамический граф вычислений: в PyTorch граф вычислений формируется динамически во время выполнения программы, что позволяет более гибко управлять процессом обучения;
3. Активное сообщество: PyTorch имеет активное сообщество разработчиков и пользователей, что обеспечивает поддержку и развитие фреймворка.

Учитывая вышеперечисленные преимущества PyTorch, выбор пал на него.

1.5 Составление технического задания

Перед выбором архитектуры моделей стоит сначала определить ограничения окружения, в котором ей предстоит работать. В нашем случае модели будет работать на виртуальной машине с характеристиками из таблицы 1.

Таблица 1 - Окружение, для работы модели

Название характеристики	Описание характеристики
RAM	8 Гб
Жесткий диск	20 Гб

Продолжение таблицы 1

CPU	4 ядра “Intel Xeon Processor (Skylake, IBRS)”
GPU	Отсутствует

Обучение происходит на сервере с характеристиками из таблицы 2.

Таблица 2 - Окружение, для обучения модели

Название характеристики	Описание характеристики
RAM	25.5 Гб
Жесткий диск	150 Гб
CPU	1 ядро “Intel(R) Xeon(R) CPU @ 2.30GHz”
GPU	1 ядро “Tesla T4”

Чтобы пользователь не ждал слишком долго, установим верхний предел для ответа сервера - 10 с.

Таким образом, техническое задание состоит в том, чтобы разработанная система смогла выдавать ответ за 10 с используя оборудование с характеристиками из таблицы 1.

2. Конструкторская часть

2.1 Обзор существующих приложений-аналогов

“AI Dermatologist: Skin Scanner” - приложение позволяет сохранять фотографии областей поражения, отмечая, в каком месте на теле находится область поражения. Приложение классифицирует заболевание при помощи технологий искусственного интеллекта. После распознавания показывает описание заболевания, дает советы по лечению, рекомендации.

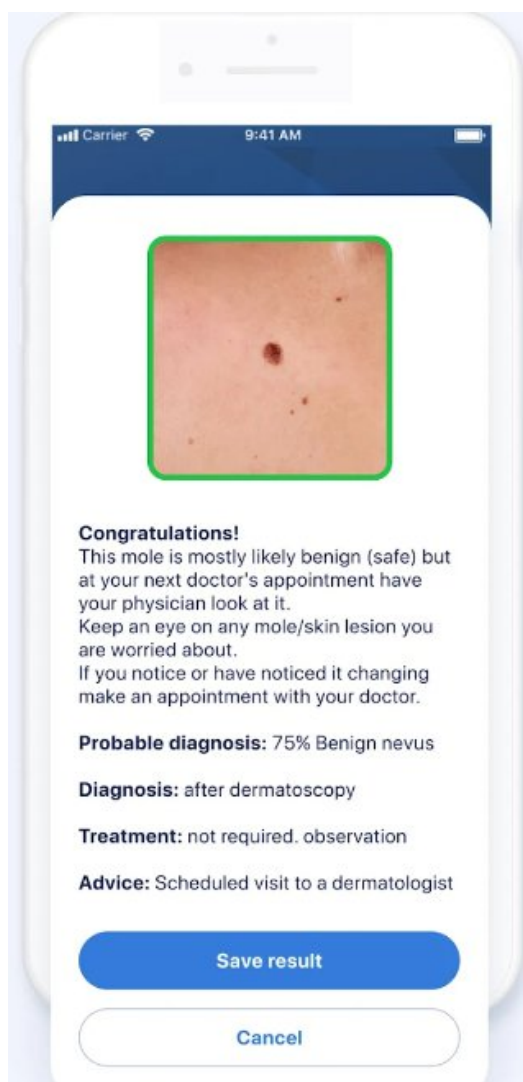


Рисунок 16 – Интерфейс приложения «AI Dermatologist: Skin Scanner» [3]

“Aysa” - приложение, которое помогает пользователю классифицировать кожное заболевание по фотографии. Помимо изображения пользователь должен ответить на дополнительные вопросы, чтобы приложение точнее определило заболевание. После ответов на вопросы пользователю демонстрируется список наиболее вероятных заболеваний.

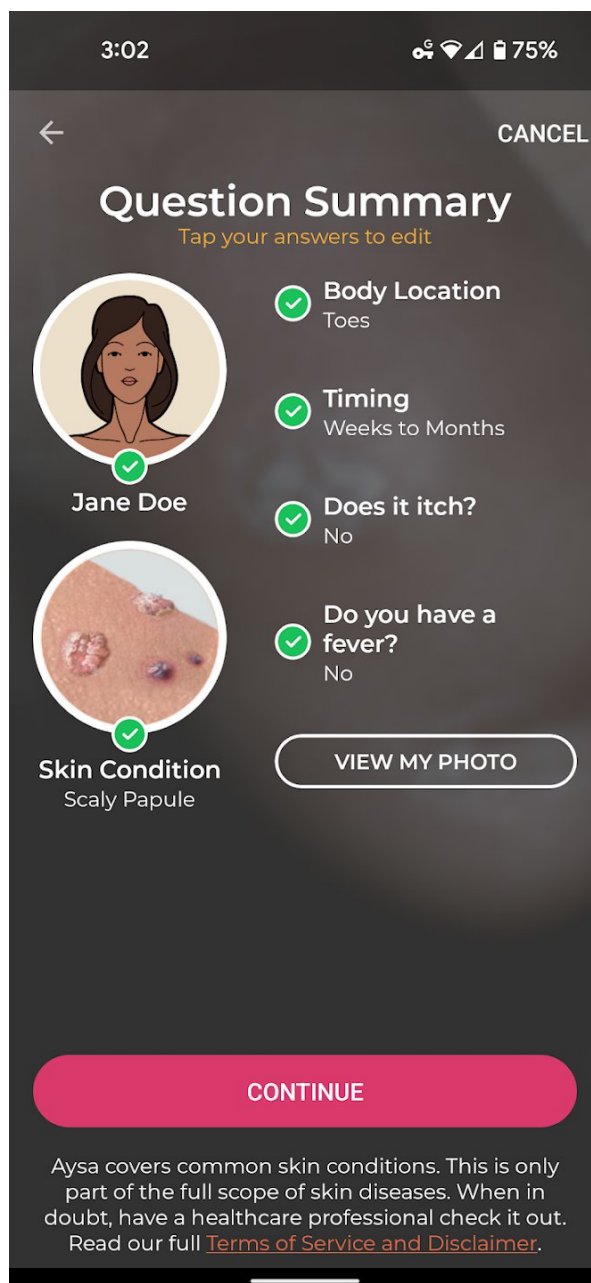


Рисунок 17 – Интерфейс приложения “Aysa” [4]

“AI Skin” - приложение предварительной диагностика кожных новообразований и высыпаний по фото с помощью искусственного интеллекта. На основе загруженных фотографий приложение оценивает вероятность наличия патологии из 7 распространенных типов заболеваний кожи. В основе

модели лежат алгоритмы искусственного интеллекта и анализ нескольких тысяч изображений.

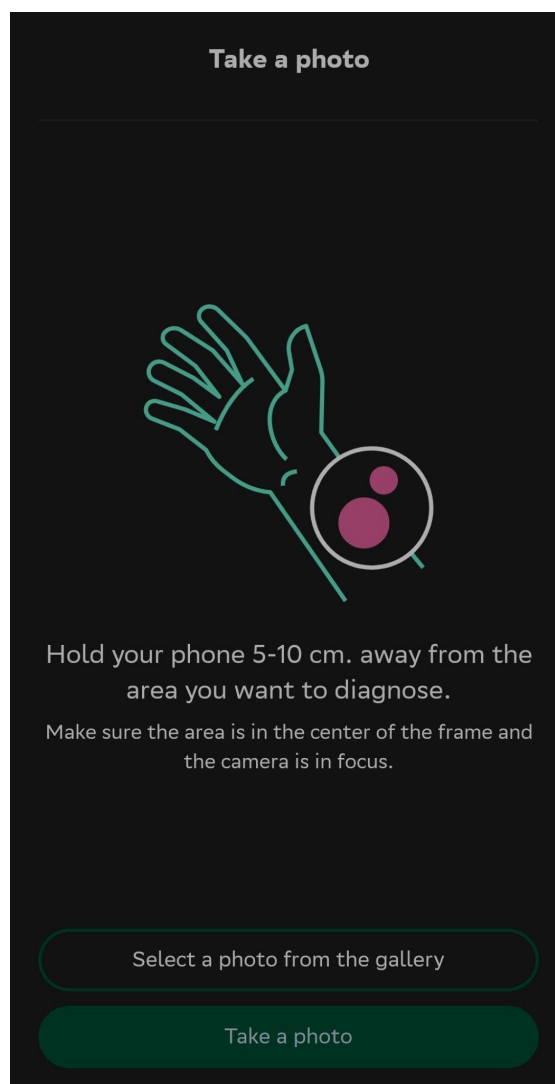


Рисунок 18 – Интерфейс приложения “AI Skin” [5]

2.2 Обоснование актуальности новой разработки

Размер области поражения - это очень важный фактор при определении кожного заболевания, так как размер поражения может указывать на степень тяжести заболевания и необходимость медицинской помощи. Кроме того, размер поражения может помочь врачу определить эффективность лечения и корректировать его при необходимости. Поэтому при использовании приложений для определения кожных заболеваний, важно обеспечить точность измерения размера поражения.

Размер меланоцитарного образования является одним из традиционных дифференциально-диагностических критериев, используемых в диагностике меланомы кожи. Согласно клиническому правилу ABCD и мнемоническому правилу ФИГАРО диаметр образования более 6 мм является основанием для подозрения меланомы. Анализ пигментных образований при помощи указанных алгоритмов может привести к осмотру только крупных образований в процессе скрининга и сформировать у врача ложное представление о начальных проявлениях этой злокачественной опухоли. В то же время изменение порогового значения в 6 мм может обусловить ухудшение клинической диагностики меланомы. Так, при уменьшении порогового значения даже на 1 мм снизится специфичность клинического правила ABCD на 16%, а при увеличении на 1 мм — чувствительность метода уменьшится на 12% [6].




Рисунок 19 – Дерматоскопическая картина меланомы диаметром 2 мм [6]

Все ранее упомянутые аналоги успешно классифицируют кожные заболевания, однако они не дают никакой информации о размере области

поражения, что сигнализирует о том, что в этом приложении есть большая потребность.

Таблица 3 - Популярность приложений, классифицирующих кожные заболевания

Название приложения	Количество скачиваний в Google Play Market
Aysa	Больше 100 000.
Больше 100 000.	Больше 500 000.
“AI Dermatologist: Skin Scanner”	Больше 100 000.

Смотря на Таблицу 1 можно заметить, что у приложений-аналогов большое количество скачиваний, что сигнализирует о высоком спросе на подобные приложения.

2.3 Обзор методов для определения размера объекта на изображении

Самые эффективные методы определения размера объекта на изображении опираются на участок изображения, размер которого может известен или может быть вычислен.

Монеты могут быть использованы для определения размера объекта на изображении. Для этого нужно знать размер монеты и поместить ее рядом с объектом, который нужно измерить. Затем можно определить размер объекта относительно размера монеты.

Например, если известно, что диаметр монеты составляет 25 мм, а на изображении она имеет диаметр 100 пикселей, то можно вычислить коэффициент пропорциональности между пикселями и миллиметрами. Затем, используя этот коэффициент, можно определить размер любого другого объекта на изображении. Важно учитывать расстояние между монетой и объективом, между объектом и объективом.

Пользователю неудобно при фотографировании каждый раз прикладывать монету или другой объект известного размера. На фотографии помимо области поражения очевидно присутствует кожный покров. Ранее были рассмотрены его составляющие. Легче всего на фото различить поры, поэтому их кол-во на фотографии можно посчитать.

Плотность пор на кожном покрове зависит от нескольких факторов, включая генетические особенности, уровень гормонов в организме, режим питания и употребляемые продукты, экологические условия и загрязнение окружающей среды, использование косметических средств и их качество, степень ухода за кожей и регулярность процедур, возраст и состояние здоровья, климатические условия и уровень влажности воздуха, наличие вредных привычек, таких как курение, стресс и недостаток сна.

Генетические особенности могут определять размер и количество пор на коже. Уровень гормонов в организме также может влиять на плотность пор, особенно у женщин во время менструации, беременности или менопаузы.

Режим питания и употребляемые продукты могут повлиять на плотность пор на коже. Переедание жирной и сладкой пищи может привести к увеличению пор, а употребление пищи, богатой антиоксидантами, может помочь снизить плотность пор.

Экологические условия и загрязнение окружающей среды могут также повлиять на плотность пор. Избыточное количество загрязнений в воздухе может привести к увеличению пор на коже.

Использование косметических средств и их качество также могут влиять на плотность пор. Некачественные косметические средства могут вызывать забивание пор, что приводит к увеличению их размера.

Степень ухода за кожей и регулярность процедур также могут влиять на плотность пор. Регулярное очищение кожи и использование средств для сужения пор могут помочь уменьшить их размер.

Возраст и состояние здоровья также могут влиять на плотность пор. С возрастом кожа теряет эластичность, что может привести к увеличению размера

пор. Некоторые заболевания, такие как акне, могут также повлиять на плотность пор.

Самыми значимыми среди вышеперечисленных факторов являются возраст, пол, этническая группа

Age group (years)	18–29	30–39	40–49	50–59	60–69	Over 70
Brazilian	91.26±14.37	81.75±16.79	68.7±12.04	61.73±7.95		
Caucasian	63.96±11.72	62.22±11.80	64.49±8.53	59.93±7.76	61.13±8.04	
Chinese	21.13±9.49	23.24±7.48	20.77±6.55	24.51±6.67	20.20±6.82	21.66±8.59
Indian	82.68±15.42	79.91±12.24	77.12±9.89	77.53±10.88	73.56±7.51	71.19±9.88
Japanese	67.41±13.95	69.64±12.10	69.78±12.71	72.44±12.89	69.75±10.22	68.83±9.01

Рисунок 20 – Данные о плотности пор на лице в зависимости от возраста и этнической группы [7]

Примечания: Данные выражены как среднее значение ± стандартное отклонение в порах/см². Ярко-серый фон (любая смежная ячейка) означает значительные различия по сравнению со всеми другими возрастными кластерами в пределах одной этнической группы. Одинаковый оттенок серого (только для среднего и темного) для смежных ячеек иллюстрирует несущественно различающиеся значения по возрастным кластерам в пределах одной этнической группы. Группа смежных ячеек с одинаковыми серыми тонами (средними и темными) значительно отличается от всех других возрастных групп внутри той же этнической группы [7].

Размер пор зависит от типа фолликула, которого существует три: первый - с длинным волосом и мелкой сальной железой, второй - с пушковым волосом и средней сальной железой, а третий - с коротким невидимым волосом и крупной сальной железой с широким устьем. Устья фолликулов третьего типа находятся на поверхности кожи и располагаются преимущественно на лице. Количество фолликулов на разных участках кожи значительно разнится: от 20-50 на тыльной стороне кистей и губах до 400-900 на квадратный сантиметр в области груди, плеч и лица. Максимальный диаметр пор составляет 2,5 мм, и они легко заметны глазом.

Зная пол, возраст, часть тела, можно узнать примерную плотность пор. Таким образом, после подсчета количества пор на фотографии появляется

возможность вычислить абсолютную площадь кожного покрова и области поражения.

2.4 Выбор набора данных

При выборе набора данных при решении задачи классификации стоит обратить внимание на его размер, количество классов, качество, разрешение изображений, источник данных.

Среди многих наборов данных, которые представляют из себя классифицированные фотографии областей поражения на коже, в этой работе выбор пал на “Dermnet”[4].

Данные “Dermnet” состоят из изображений 23 типов кожных заболеваний. Общее количество изображений составляет около 19 500, из которых примерно 15 500 были разделены на обучающий набор, а остальные — на тестовый набор.

Изображения представлены в формате JPEG, состоящем из 3-х каналов, т.е. RGB. Разрешения варьируются от изображения к изображению и от категории к категории, но в целом это изображения не с очень высоким разрешением.

Категории включают акне, меланому, экзему, себорейный кератоз, стригущий лишай, буллезную болезнь, ядовитый плющ, псориаз, сосудистые опухоли и т. д.

Изображения взяты с общедоступного портала «Dermnet», который является крупнейшим онлайн-ресурсом по дерматологии, созданным с целью предоставления онлайн-медицинского образования. Известный источник данных гарантирует качество набора данных

2.5 Обзор архитектур нейронных сетей для классификации объектов на изображении

2.5.1 Архитектура ResNet

ResNet — это сокращенное название для Residual Network (дословно — «остаточная сеть»), но что такое residual learning («остаточное обучение»)?

Когда более глубокая сеть начинает сворачиваться, возникает проблема: с увеличением глубины сети точность сначала увеличивается, а затем быстро ухудшается. Снижение точности обучения показывает, что не все сети легко оптимизировать.

Чтобы преодолеть эту проблему, Microsoft ввела глубокую «остаточную» структуру обучения. Вместо того, чтобы надеяться на то, что каждые несколько stacked layers непосредственно соответствуют желаемому основному представлению, они явно позволяют этим слоям соответствовать «остаточному». Формулировка $F(x) + x$ может быть реализована с помощью нейронных сетей с соединениями для быстрого доступа. [8]




Рисунок 21 – Соединение быстрого доступа [8]

Соединения быстрого доступа (shortcut connections) пропускают один или несколько слоев и выполняют сопоставление идентификаторов. Их выходы добавляются к выходам stacked layers. Используя ResNet, можно решить множество проблем, таких как:

- ResNet относительно легко оптимизировать: «простые» сети (которые просто складывают слои) показывают большую ошибку обучения, когда глубина увеличивается.
- ResNet позволяет относительно легко увеличить точность благодаря увеличению глубины, чего с другими сетями добиться сложнее.

2.5.2 Архитектура EfficientNet

Изучая масштабирование моделей и балансирование между собой глубины и ширины (количества каналов) сети, а также разрешение изображений в сетке. Был предложен новый метод масштабирования, который равномерно масштабирует глубину/ширину/разрешение. Его эффективность на MobileNet и ResNet показана на рисунку ниже.

При помощи использования Neural Architecture Search для создания новой сетки и масштабирования её, тем самым получая класс новых моделей – EfficientNets. Они лучше и намного экономнее предыдущих сеток. На ImageNet EfficientNet-B7 достигает state-of-the-art 84.4% top-1 и 97.1% top-5 accuracy, будучи при этом в 8.4 раза меньше и в 6.1 раз быстрее на инференсе, чем текущая лучшая по точности ConvNet. Хорошо трансферится на другие датасеты – получили SOTA на 5 из 8 наиболее популярных датасетов [9].




Рисунок 22 – Зависимость миллионов параметров от точности для различных архитектур [9]

2.5.3 Архитектура DenseNet

DenseNet (Densely Connected Convolutional Network) была предложена в 2017 году. Успех ResNet (Deep Residual Network) позволил предположить, что укороченное соединение в CNN позволяет обучать более глубокие и точные модели. Проанализировали это наблюдение был представлен компактно соединенный (dense) блок, который соединяет каждый слой с каждым другим слоем. Важно отметить, что, в отличие от ResNet, признаки («фичи») прежде чем они будут переданы в следующий слой не суммируются, а конкатенируются (объединяются, channel-wise concatenation) в единый тензор. При этом количество параметров сети DenseNet намного меньше, чем у сетей с такой же

точностью работы. Утверждается, что DenseNet работает особенно хорошо на малых наборах данных [10].

Пример плотного блока приведен на рисунке ниже.




Рисунок 23 – Один плотный блок DenseNet с 5 слоями и скоростью роста $k = 4$. Каждый слой принимает все предыдущие карты признаков в качестве входных данных [10]

2.5.4 Архитектура SwinV2

У архитектуры SwinV1 есть проблема с нестабильным обучением. Это в значительной степени вызвано тем, что активация сети на более поздних уровнях модели значительно выше, чем на более ранних уровнях, из-за конструкции, в которой выходные данные остатка напрямую добавляются обратно в основную ветвь, что приводит к нестабильному обучению.

Чтобы решить первую проблему, слой нормализации уровня (LN) перемещается из передней части в заднюю часть остаточной единицы, как показано на рис. 8. Кроме того, масштабированное косинусное внимание заменяет версию собственного внимания с умножением матриц в V1, чтобы модель совершенно нечувствительна к величине (крупности) активаций. [11]

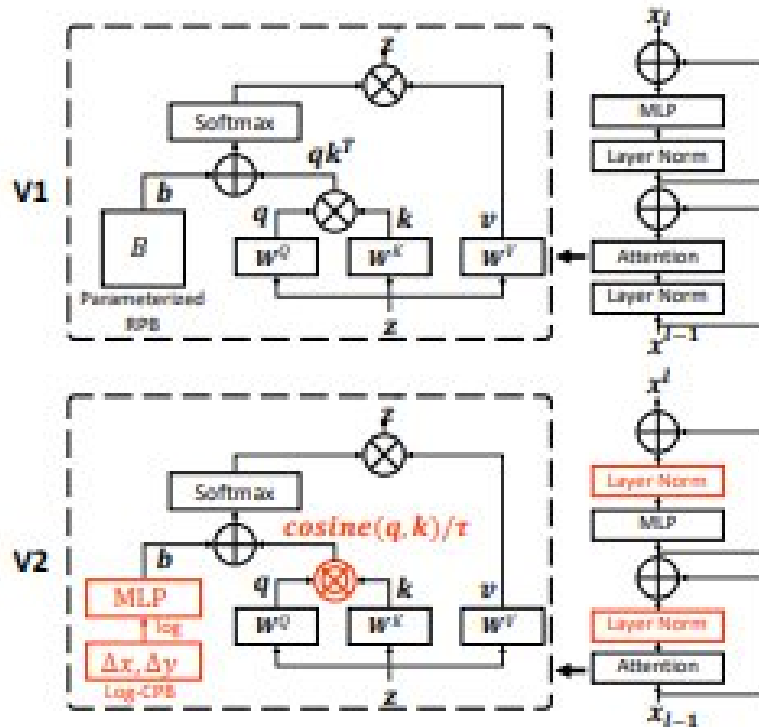


Рисунок 24 – Отличие архитектуры SwinV2 от SwinV1 [11]

Два решения первой проблемы успешно улучшили стабильность обучения и точность модели для более крупных моделей.

Несоответствие размера изображения предварительной подготовки и обучения

Размеры изображений между предварительно обученными входными изображениями и входными изображениями с точной настройкой (позднее обучение) сильно различаются. В настоящее время широко практикуется наивное изменение размера с использованием бикубической интерполяции. Однако этого недостаточно.

Чтобы решить эту проблему, авторы использовали новую систему координат, координаты с логарифмическим интервалом, чтобы заменить

предыдущие координаты с линейным интервалом. Поэтому изображения сначала преобразуются в эту новую систему координат, прежде чем поступать в сеть. Новая система координат значительно сократила разрыв между несоответствием размера изображения перед обучением и точной настройкой из-за характера логарифмической функции.

Кроме того, чтобы решить проблему высокого потребления памяти графическим процессором в результате масштабирования сети, реализован ряд методов, включая оптимизацию нуля, контрольную точку активации и последовательное вычисление внутреннего внимания (не будет описываться в этой статье).

Method	param	pre-train images	pre-train length (#im)	pre-train im size	pre-train time	fine-tune im size	ImageNet-1K-V1 top-1 acc	ImageNet-1K-V2 top-1 acc
SwinV1-B	88M	IN-22K-14M	1.3B	224 ²	<30 [†]	384 ²	86.4	76.58
SwinV1-L	197M	IN-22K-14M	1.3B	224 ²	<10 [†]	384 ²	87.3	77.46
ViT-G [80]	1.8B	JFT-3B	164B	224 ²	>30k	518 ²	90.45	83.33
V-MoE [56]	14.7B*	JFT-3B	-	224 ²	16.8k	518 ²	90.35	-
CoAtNet-7 [17]	2.44B	JFT-3B	-	224 ²	20.1k	512 ²	90.88	-
SwinV2-B	88M	IN-22K-14M	1.3B	192 ²	<30 [†]	384 ²	87.1	78.08
SwinV2-L	197M	IN-22K-14M	1.3B	192 ²	<20 [†]	384 ²	87.7	78.31
SwinV2-G	3.0B	IN-22K-ext-70M	3.5B	192 ²	<0.5k [†]	640 ²	90.17	84.00

Рисунок 25 – Статистика моделей для Swin Transformer V1 и V2 и некоторых популярных Transformers компьютерного зрения. [11]

Как показано на рисунке 25, предлагаются два варианта V1 и три варианта V2 с различными размерами. V2 успешно улучшил производительность V1 и достиг результатов, близких к SOTA, с более эффективными вычислениями в ImageNet.

2.6 Подготовка данных для обучения

Аугментация данных изображений - это процесс создания новых изображений путем применения различных трансформаций к существующим изображениям. Это позволяет увеличить размер обучающего набора данных и улучшить качество обучения сверточной нейронной сети.

Примерами трансформаций могут быть изменение размера изображения, поворот, отражение, изменение яркости и контрастности, добавление шума и т.д. Эти трансформации могут помочь сети обучаться на более разнообразных данных и увеличить ее устойчивость к изменениям в данных.

Аугментация данных изображений может быть особенно полезна в случаях, когда доступ к большому количеству реальных данных ограничен. Она может помочь создать большой и разнообразный обучающий набор данных, который может улучшить качество предсказаний сверточной нейронной сети.

В целом, аугментация данных изображений является важным инструментом для улучшения качества обучения сверточных нейронных сетей в области компьютерного зрения.

При помощи библиотеки `torchvision.transforms` для языка программирования Python была произведена аугментация исходных изображений:

- Изменение контрастности;
- Изменение яркости;
- Поворот по горизонтали;
- Изменение размера;
- Обрезание по центру.

Исходный набор данных уже разбит на тренировочную и тестовую выборку, поэтому нам нет необходимости его разбивать

2.7 Обучение моделей

Обучение моделей происходило в 8 эпох. В качестве функции потерь использовался `CrossEntropyLoss` из библиотеки `PyTorch`. Для создания загрузчика данных использовался метод `DataLoader` из `PyTorch`, размер пачки данных в нем равен 32.

Была выбрана предобученная на наборе данных ImageNet архитектура `ResNet50`, которая содержит 50 слоев.




Рисунок 26 – Функция потерь по эпохам при обучении `ResNet`




Рисунок 27 – Точность по эпохам при обучении ResNet

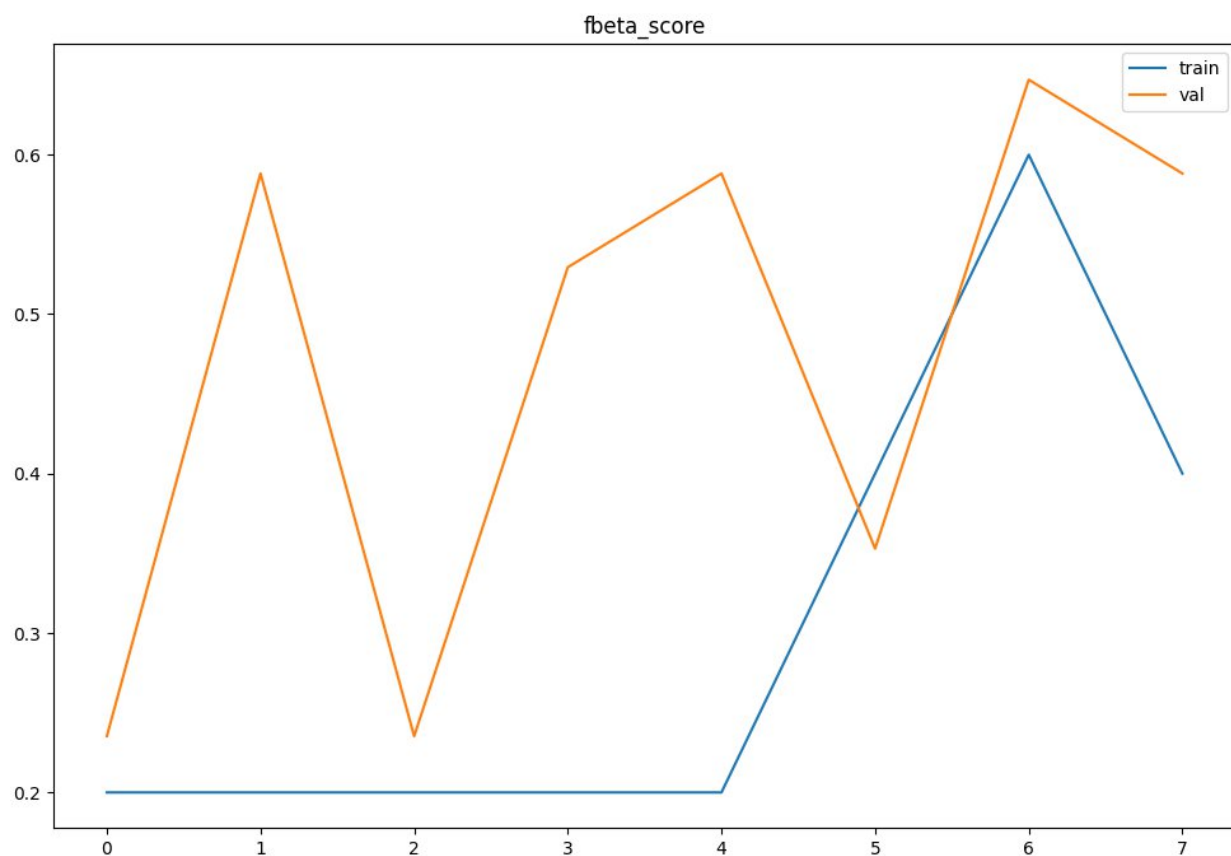


Рисунок 28 – f2-score по эпохам при обучении ResNet




Рисунок 29– Матрица ошибок ResNet50

Была выбрана предобученная на наборе данных ImageNet архитектура EfficientNet_v2.




Рисунок 30 – Функция потерь по эпохам при обучении EfficientNet




Рисунок 31 – Точность по эпохам при обучении EfficientNet




Рисунок 32 – Метрика “f2-score” при обучении EfficientNet

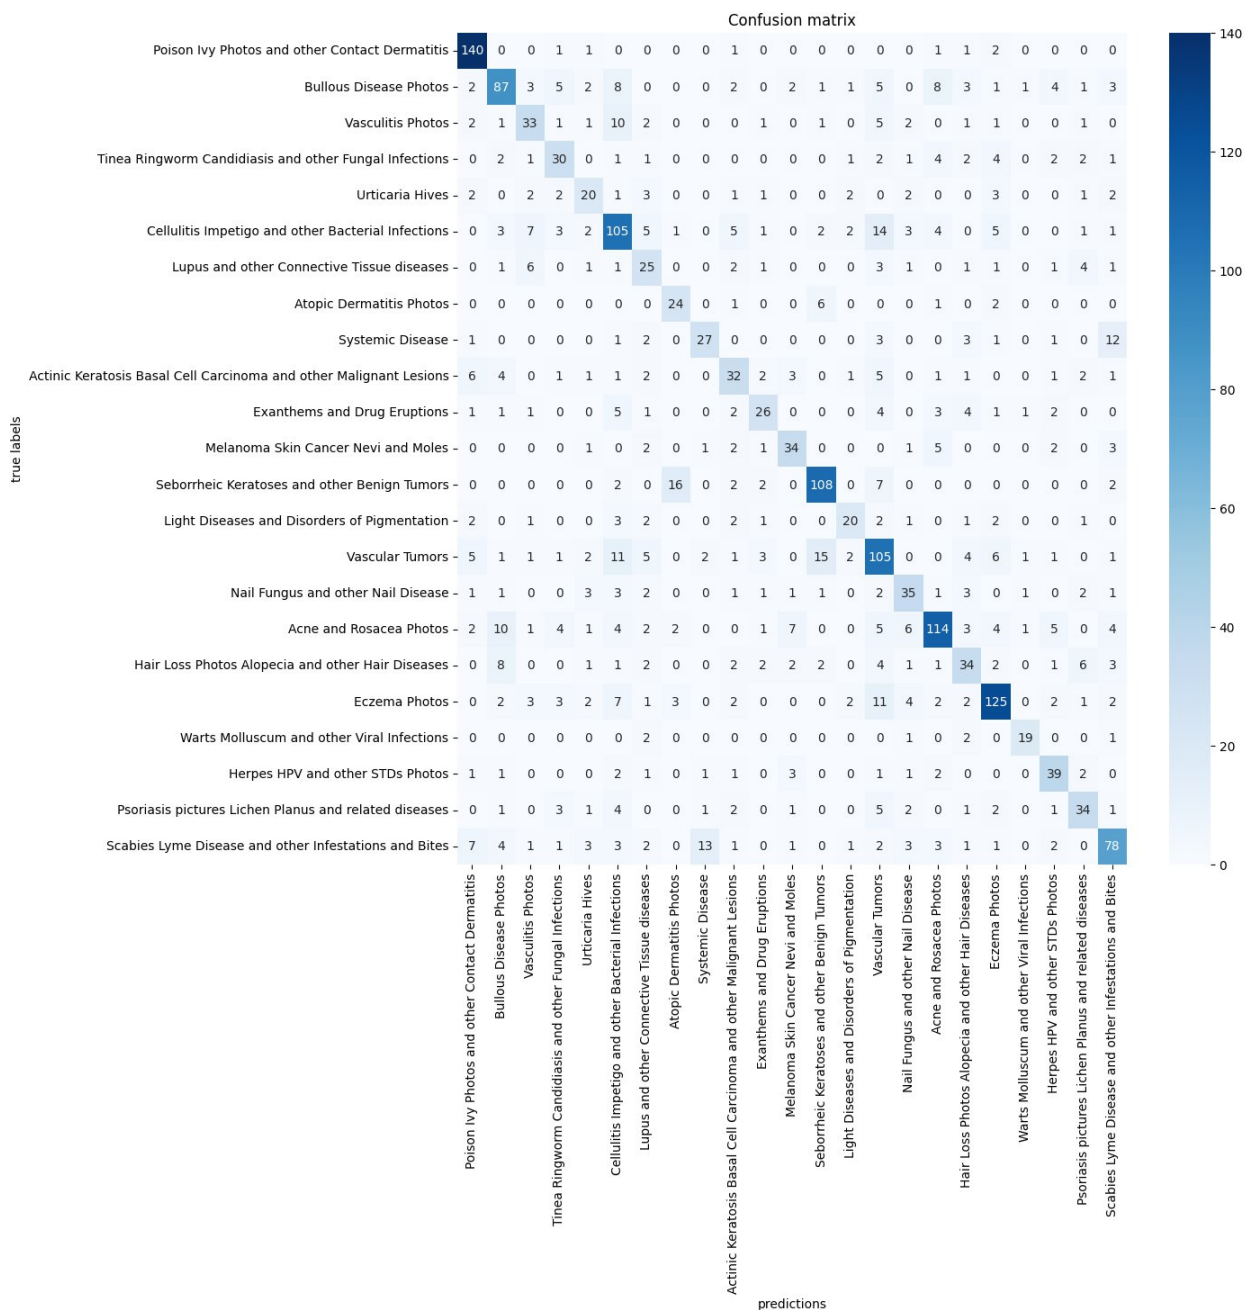


Рисунок 33 – Матрица ошибок EfficientNet

Была выбрана предобученная на наборе данных ImageNet архитектура Densenet.




Рисунок 34 – Функция потерь по эпохам при обучении DenseNet

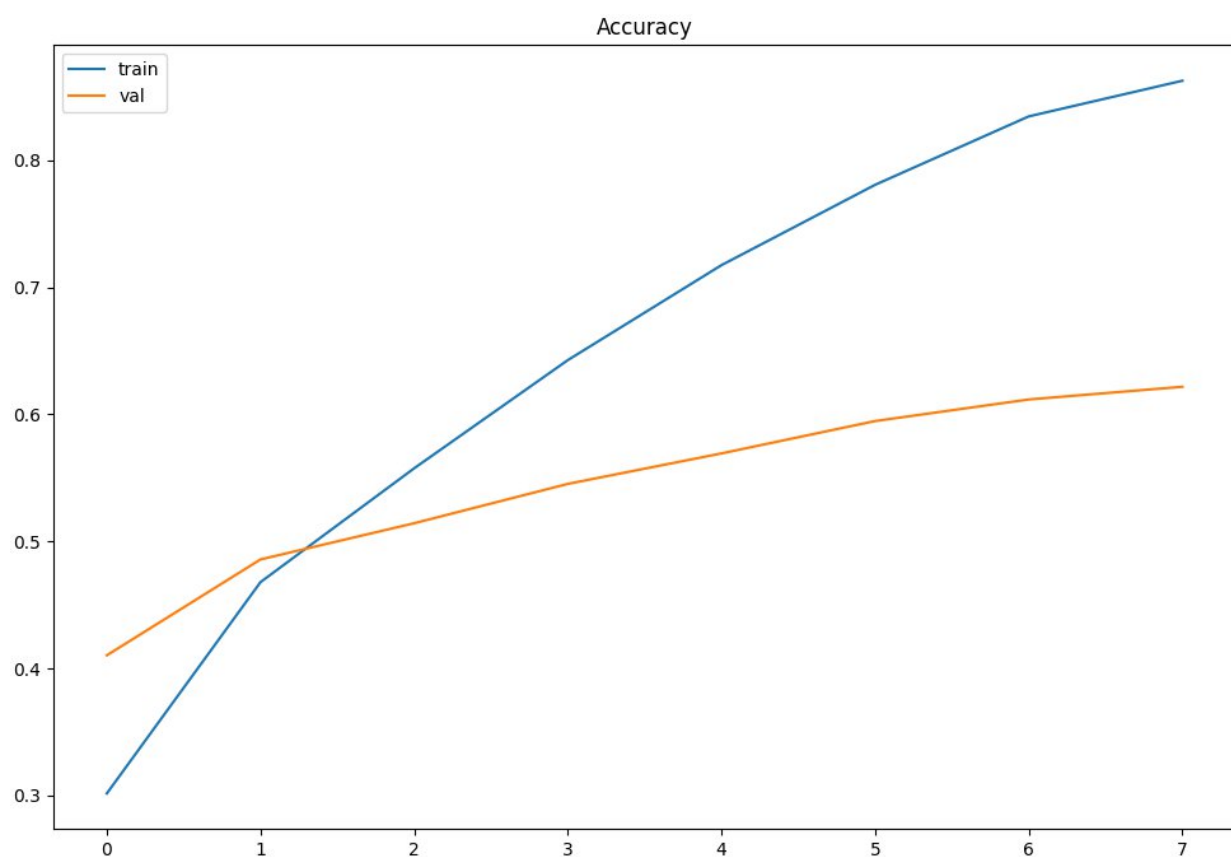


Рисунок 35 – Точность по эпохам при обучении DenseNet




Рисунок 36 – f2-score по эпохам при обучении DenseNet




Рисунок 37 – Матрица ошибок DenseNet

Была выбрана предобученная на наборе данных ImageNet архитектура SwinV2.




Рисунок 38 – Функция потерь по эпохам при обучении SwinV2




Рисунок 39 – Точность по эпохам при обучении SwinV2




Рисунок 40 – f2-score по эпохам при обучении DenseNet

по эпохам при обучении SwinV2




Рисунок 41 – Матрица ошибок SwinV2

2.8 Сравнение результатов обучения различных архитектур

Сравнение изменение ошибки по эпохам для различных моделей представлено на рисунке 26.




Рисунок 42 – Функция ошибок по эпохам для различных архитектур

Сравнение точности по эпохам для различных моделей представлено на рисунке 43.




Рисунок 43– Точность по эпохам для различных архитектур

Сравнение f2-score по эпохам для различных моделей представлено на рисунке 28.




Рисунок 44 – f2-score по эпохам для различных архитектур




Рисунок 45 - время предсказания по эпохам для различных архитектур

Лучшее качество предсказания дала архитектура SwinV2, затратив не сильно больше времени на обучение, затратив не сильно больше времени на предсказание. Учитывая вычислительную мощность сервера, где будет происходить предсказание целесообразно взять SwinV2, потому что она обладает наилучшим показателем точности и удовлетворяет временным рамкам.

2.9 Модель для сегментации изображения

2.9.1 Выбор набора данных для обучение модели сегментации

Среди общедоступных наборов данных для сегментации изображений кожных заболеваний есть только наборы изображений меланомы. Поэтому будем использовать именно его.

Набор данных PH2 был разработан для исследовательских и сравнительных целей, чтобы облегчить сравнительные исследования как алгоритмов сегментации, так и классификации дерматоскопических изображений. PH2 — это база данных дерматоскопических изображений, полученная в Дерматологической службе больницы Педро Испано, Матозиньюш, Португалия.




Рисунок 46 – Примеры изображений и их сегментированной части из набор данных PH2

2.9.2 Обоснование выбора архитектуры для модели сегментации кожного заболевания

U-net — это метод сегментации изображений, разработанный в первую очередь для задач сегментации изображений. Эти черты обеспечивают высокую полезность U-net в сообществе медицинских изображений и привели к широкому внедрению U-net в качестве основного инструмента для задач сегментации в медицинской визуализации. Успех U-net очевиден в его широком использовании почти во всех основных модальностях изображений, от компьютерной томографии и МРТ до рентгеновских лучей и микроскопии. Кроме того, хотя U-net в значительной степени является инструментом сегментации, были случаи использования U-net в других приложениях.

Как упоминалось ранее, сеть U-net можно разделить на две части: первая — это контрактный путь, использующий типичную архитектуру CNN. Каждый блок на пути сокращения состоит из двух последовательных сверток 3×3 , за которыми следует блок активации ReLU и слой максимального объединения. Это расположение повторяется несколько раз. Новинка U-net представлена во второй части, называемой экспансивным путем, в котором на каждом этапе повышается дискретизация карты признаков с использованием свертки с повышением частоты 2×2 . Затем карта объектов из соответствующего слоя на пути сокращения обрезается и объединяется с картой объектов с повышенной дискретизацией. Затем следуют две последовательные свертки 3×3 и активация ReLU.

На заключительном этапе применяется дополнительная свертка 1×1 для уменьшения карты признаков до необходимого количества каналов и получения сегментированного изображения. Обрезка необходима, поскольку пиксельные элементы по краям содержат наименьшее количество контекстной информации и поэтому должны быть отброшены. Это приводит к тому, что сеть напоминает U-образную форму и, что более важно, распространяет контекстную информацию по сети, что позволяет ей сегментировать объекты в области, используя контекст из большей перекрывающейся области. На рис. 47 показана общая архитектура U-net [12].




Рисунок 47 – Общая архитектура U-net [12]

Высокие результаты в медицинских изображениях, достижение высокой точности при обучении на относительно небольшом наборе данных - это преимущества, которые стали решающими в выборе U-net в качестве архитектуры модели сегментации меланомы.

2.9.3 Обучение модели сегментации

Обучение данной модели происходило в 20 эпох. В функции оценки качества модели было решено использовать Intersection over Union (IoU). IoU считает перекрытие, деленное на объединение верной сегментации и полученной сегментации от модели. Для избежания деления на ноль в знаменателе добавлено очень маленькое постоянное слагаемое. В качестве функции потерь используется BCE loss.




Рисунок 48 - Функция потерь по эпохам при обучении U-net




Рисунок 49 - Точность предсказания по эпохам при обучении U-net




Рисунок 50 - Пример предсказания после обучения U-net

2.11 Алгоритм выделения пор на изображении

Рассмотрим всю цепочку преобразований исходного изображения для подсчета пор, инструменты, при помощи которых они были реализованы [15].

Исходное изображение имеет вид массива размерности 256, 256, 3 в цветовой модели RGB.




Рисунок 51 - Исходное изображение для подсчета пор

Далее повысим контрастность изображения при помощи метода CLAHE. Была использована его реализация из библиотеки `opencv` в виде метода `“createCLAHE”` [13].




Рисунок 52 - Контрастное изображение

Затем было произведено сравнение каждого пикселя с пороговым значением с целью получения черно-белого изображения




Рисунок 53 - Черно-белое изображение

После этого следует удалить с изображения область поражения, потому что на ней расположен очаг заболевания, не видно поры. Для этого полученное после сегментации изображение “вычтем” из черно-белого. Результат приведен на рисунке 55.




Рисунок 54 - Результат сегментации




Рисунок 55 - Результат “вычитания”

Можно заметить, что на исходной фотографии слишком много шума в виде небольших точек. Избавиться от него можно при помощи метода, который

оставляет только те белые точки, вокруг которых тоже есть белые точки. В данной работе была использована реализация из библиотеки scikit-image в виде метода под названием: “binary_erosion” [14].




Рисунок 56 - Результат применения метода binary_erosion

Теперь стоит убедиться, что поры выделены корректно, в этом можно убедиться, посмотрев на рисунок 57.




Рисунок 57 - Наложение выделенных пор на исходный рисунок

Далее для подсчета пор используем метод `regionprops` из библиотеки `scikit-image`. Полученное значение - 66. Ручной подсчет дал результат в 71 пору. Чтобы корректно измерить точность подсчета пор требуется достаточно большой набор данных, которого нет в открытом доступе.

Далее для вычисления площади кожного покрова рассчитываем количество пикселей, которое занимает кожа без области поражения. Умножив на известную площадь для данного участка тела, данного человека, получим значение 1,52 см². Умножив полученное значение на относительную площадь области поражения, деленную на относительную площадь кожного покрова на изображении получим абсолютную площадь области поражения.

$$S_1 \times \frac{N}{M} = S_2, \quad (1)$$

$N = 11925$ - пикселей области поражения;

$M = 53611$ - пикселей кожного покрова;

$S_1 = 1,52$ см² - площадь кожного покрова;

$S_2 = 0,27$ см² - площадь области поражения.

Итоговое значение площади области поражения равно 0,27 см².

Из исследования [6] известно, что помимо площади важным параметром для оценки стадии развития меланомы является ее диаметр. Под диаметром области поражения подразумевается диаметр окружности, описанной около области поражения. Для подсчета данного диаметра воспользуемся методами `findContours` и `minEnclosingCircle` из библиотеки `OpenCV`.




Рисунок 58 - Окружность, описанная около области поражения

Метод `minEnclosingCircle` возвращает координаты центра окружности и её радиус. Сторона изображения равна 256 пикселям. Сторона изображения имеет длину, равную квадратному корню из площади всего видимого участка тела.

$$D = 2 \frac{\sqrt{S_1 + S_2}}{L} \times R, \quad (2)$$

где $S_1 = 1,52 \text{ см}^2$ - площадь кожного покрова;

$S_2 = 0,27 \text{ см}^2$ - площадь области поражения;

$L = 256$ - длина стороны изображения в пикселях;

$R = 74$ - радиус окружности около области поражения в пикселях;

$D = 0,77$ см - диаметр области поражения.

2.11 Бот для взаимодействия с алгоритмом распознавания

Для удобного взаимодействия с алгоритмом распознавания был запрограммирован чат-бот в Telegram. Причины, по которым был выбран чат-бот, а не сайт:

- 1) Чат-бот требует меньше времени на разработку;
- 2) Быстрота и эффективность - телеграм-боты могут обрабатывать большое количество запросов на обслуживание клиентов и оперативно предоставлять ответы.

В качестве основного языка программирования серверной части был выбран Go. Выбор был сделан, учитывая его преимущества:

- 1) Go был разработан с целью обеспечения быстрого выполнения кода. Он использует, распараллеливание и конкурентность, что позволяет ускорять выполнение операций;
- 2) Надёжность: Go считается достаточно надёжным языком программирования, так как обладает высоким уровнем стабильности и безопасности. Более того, Go предоставляет API для обработки ошибок, что значительно упрощает процесс отладки программы.

Микросервис с распознаванием написан на языке программирования Python. Общение между микросервисами осуществляется при помощи протокола GRPC.

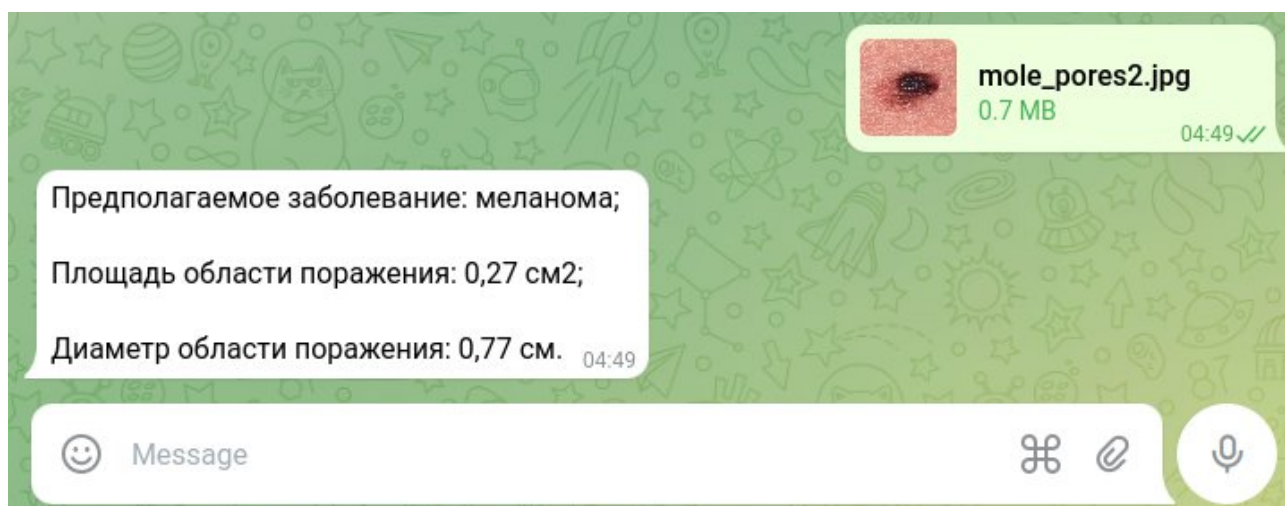


Рисунок 59 - Успешное распознавание

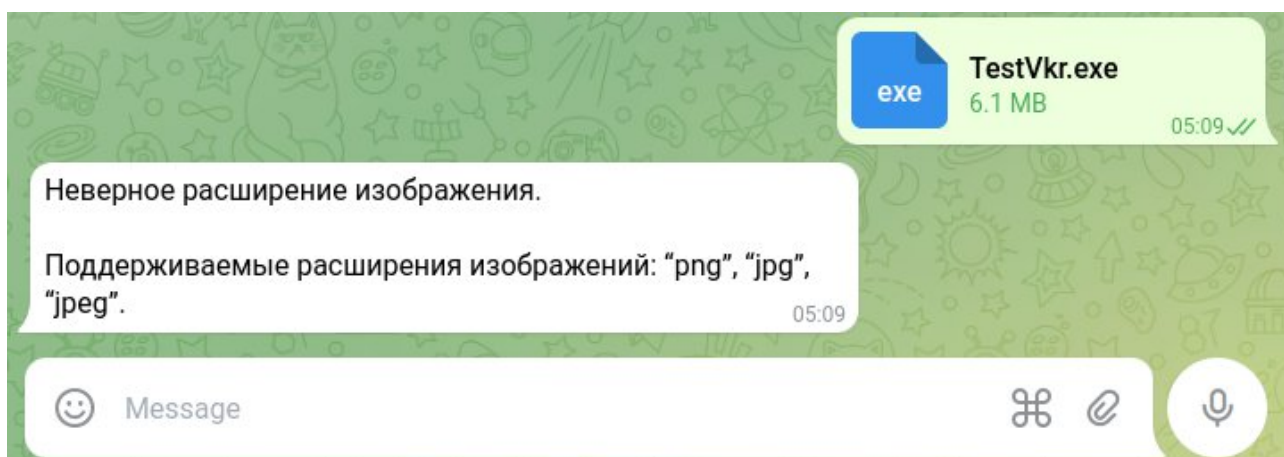


Рисунок 60 - Сообщение об ошибке из-за неверного расширения файла изображения

3. Технологическая часть

Проверим, как система будет реагировать на:

- некорректное расширение файла;
- корректное расширение файла;
- отсутствие области поражения заболевания на изображении;
- фотографию с областью поражения заболевания, которое не получается сегментировать;
- фотографию с областью поражения заболевания, которое получается сегментировать;
- изображение, на котором неразличимы поры;
- изображение, на котором различимы поры.

Таблица 4 – Тестирование входного изображения

Форма	Формат данных	Действия	Ожидаемая реакция системы	Реакция системы
Загрузка изображения	- изображение	Загрузка файла с некорректным расширением	Сообщение “Неверное расширение файла, допускаются расширения: “jpg”, “jpeg”, “png””	Сообщение “Неверное расширение файла, допускаются расширения: “jpg”, “jpeg”, “png””
		Загрузка файла с корректным расширением	Сообщение с результатами распознавания заболевания	Показ результата распознавания заболевания

Продолжение таблицы 4

Загрузка изображения	- изображение	Загрузка изображения с отсутствием области поражения заболевания	Сообщение “На фото не удалось распознать заболевание”	Сообщение “На фото не удалось распознать заболевание”
		Загрузка фотографии с областью поражения заболевания, которое не сегментируется системой	Сообщение только с результатом классификации	Сообщение только с результатом классификации
		Загрузка изображения с заболеванием, которое сегментируется системой, на котором неразличимы поры	Сообщение с результатом классификации и сообщение “Не удалось распознать поры на фото”	Сообщение с результатом классификации и сообщение “Не удалось распознать поры на фото”

Продолжение таблицы 4

Загрузка изображения	- изображение	Загрузка изображения с заболеванием, которое сегментируется системой, на котором различимы поры	Сообщение с результатом классификации и площадью области поражения	Сообщение с результатом классификации и площадью поражения
		Загрузка изображения с качеством ниже 256×256	Сообщение “Качество фото слишком низкое”	Сообщение “Качество фото слишком низкое”

ЗАКЛЮЧЕНИЕ

В данной работе создана информационная система для анализа фотографий областей поражения кожным заболеванием. Пользователь может получить быструю диагностику по фотографии, загрузив фотографию и дополнительную информацию о себе.

В процессе опросов был исследован уровень доверия к системам искусственного интеллекта, связанных со здоровьем. Получен результат, который показывает полезность сервиса для значительной части респондентов.

При проектировании сервиса были обучены, проанализированы модели со следующими архитектурами нейронных сетей: ResNet, EfficientNet, DenseNet, SwinV2. Была выбрана архитектура, которая обладает наивысшим качеством распознавания и соответствует требованиям производительности.

В данной работе производится проектирование информационной системы для классификации кожных заболеваний на изображении. В настоящее время появляется все больше возможностей внедрять технологии машинного обучения в медицину, что связано с ростом доступности больших вычислительных мощностей. Информационная система предназначена для пользователей, которые хотят быстро получить информацию об области поражения кожным заболеванием.

Проектирование проводилось с учётом основных принципов:

- реализация методов, должна обеспечивать приемлемое время анализа изображения;

- информационная система должна обрабатывать изображения различных форматов;

Выполнение расчетов проводилось с использованием ЭВМ.

При выполнении технического проекта были проведены: анализ популярных современных архитектур нейронных сетей для классификации

кожных заболеваний на изображении, реализован алгоритм сегментации и подсчета пор на поверхности кожи по изображению кожи.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Набор данных о кожных заболеваниях [Электронный ресурс] – Режим доступа: <https://dermnet.com/> (дата обращения 21.05.2023)
2. Дерматовенерология [Электронный ресурс]: учебник / Чеботарев В.В., Тамразова О.Б., Чеботарева Н.В., А.В. Одинец - М.: ГЭОТАР-Медиа, 2013. – <http://www.rosmedlib.ru/book/ISBN9785970425916.html>
3. Описание приложения «AI Dermatologist: Skin Scanner» [Электронный ресурс] – Режим доступа: https://play.google.com/store/apps/details?id=com.aidermatologist&hl=en_US (дата обращения 21.05.2023)
4. Описание приложения «Aysa» [Электронный ресурс] – Режим доступа: <https://play.google.com/store/apps/details?id=com.visualdx.aysa&hl=ru&gl=US> (дата обращения 21.05.2023)
5. Описание приложения «AI Skin» [Электронный ресурс] – Режим доступа: <https://sbermed.ai/b2c-products/ai-skin/> (дата обращения 21.05.2023)
6. Сергеев Ю.Ю., Мордовцева В.В. Опыт диагностики меланомы кожи диаметром менее 6 мм. Клиническая дерматология и венерология. 2018;17(4):97-105.
7. Flament, F.; Francois, G.; Qiu, H.; Ye, C.; Hanaya, T.; Batisse, D.; Cointereau-Chardon, S.; Seixas, M.D.G.; Belo, S.E.D.; Bazin, R. Facial skin pores: A multiethnic study. Clin. Cosmet. Investig. Dermatol. 2015,8, 85–93.
8. Описание ResNet [Электронный ресурс] – Режим доступа: <https://neurohive.io/ru/vidy-nejrosetej/resnet-34-50-101/> (дата обращения 21.05.2023)
9. Mingxing, Tan EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks / Tan Mingxing // International Conference on Machine Learning. – 2019. – № 2019. – С. 52-58.

10. Gao Huang, Zhuang Liu, Laurens van der Maaten, Kilian Q. Weinberger, И. И. Densely Connected Convolutional Networks / Gao Huang, Zhuang Liu, Laurens van der Maaten, Kilian Q. Weinberger // International Conference on Machine Learning. – 2019. : электронный журнал. – URL: <https://arxiv.org/abs/1608.06993>. – Дата публикации: 2016.
11. Ze Liu, Han Hu, Yutong Lin, Zhuliang Yao, Zhenda Xie, Yixuan Wei, Jia Ning, Yue Cao, Zheng Zhang, Li Dong, Furu Wei, Baining Guo, Liu Swin Transformer V2: Scaling Up Capacity and Resolution / Ze Liu, Han Hu, Yutong Lin, Zhuliang Yao, Zhenda Xie, Yixuan Wei, Jia Ning, Yue Cao, Zheng Zhang, Li Dong, Furu Wei, Baining Guo // Cornell University Journal : электронный журнал. – URL: <https://arxiv.org/abs/2111.09883>. – Дата публикации: 18.11.2022.
12. N. Siddique, S. Paheding, C. P. Elkin and V. Devabhaktuni, "U-Net and Its Variants for Medical Image Segmentation: A Review of Theory and Applications," in IEEE Access, vol. 9, pp. 82031-82057, 2021, doi: 10.1109/ACCESS.2021.3086020.
13. Документация OpenCV [Электронный ресурс] – Режим доступа: https://docs.opencv.org/4.x/d6/dc7/group__imgproc__hist.html (дата обращения 21.05.2023)
14. Документация scikit-image [Электронный ресурс] – Режим доступа: https://scikit-image.org/docs/stable/api/skimorphology.html#skimage.morphology.binary_erosion (дата обращения 21.05.2023)
15. Код алгоритма для выделения пор [Электронный ресурс] – Режим доступа: <https://github.com/illyz2/pore-detection/blob/main/porealgorithms.m> (дата обращения 21.05.2023)

ПРИЛОЖЕНИЕ А

Графическая часть выпускной квалификационной работы

В графическую часть выпускной квалификационной работы входят:

1. Результаты опроса №1
2. Результаты опроса №2
3. Алгоритм подсчета пор
4. Процесс обучения модели SwinV2 для классификации кожных заболеваний
5. Сравнение полученных характеристик различных архитектур во время обучения
6. Строение кожного покрова
7. Устройство чат-бота в Telegram
8. Процесс обучения модели U-net для сегментации меланомы